UNIMAR, Marília

Marília DataHub: Plataforma Municipal de Administração e Qualidade de Dados

Danilo Queiroz Luiz
Kelvin Rodrigues dos Santos
Larah Cezário Lima da Silva
Lucas Nakamura Dias Moraes
Rafaela Tavares Návia

2026

SUMÁRIO

1. INTRODUÇÃO.....3

2. JUSTIFICATIVA.....3

3. OBJETIVOS.....4

3.1 OBJETIVOS GERAIS.....4

3.2 OBJETIVOS ESPECÍFICOS.....4

4. METODOLOGIA.....4

4.1 ARQUITETURA DO BANCO DE DADOS.....4

4.2 MINERAÇÃO DE DADOS.....4

4.3 CONTROLE DE QUALIDADE POR IA.....4

4.4 BACKEND.....4

4.5 FRONTEND.....4

4.6 FLUXOGRAMA GERAL.....4

5. DESENVOLVIMENTO.....4

6. RESULTADOS PRELIMINARES.....4

7. REFERÊNCIAS BIBLIOGRÁFICAS.....4

1. INTRODUÇÃO

Segundo Almeida et al. (2024), a utilização de tecnologias da Indústria 4.0 é considerada como uma estratégia para tornar os processos mais eficientes e alcançar a máxima qualidade nos produtos. Pensando nisso, a disciplina de Fábrica de Projetos Ágeis II propõe o desenvolvimento de soluções com inteligência artificial para problemas reais do cotidiano de parceiras acadêmicas, como a STI - Secretaria de Tecnologia e Inovação de Marília, colaboradora dos alunos do 2º semestre de IA (Inteligência Artificial). Visto que a secretaria atua no modelo matricial e transversal, gerenciando a infraestrutura de TIC (Tecnologia da Informação e Comunicação), o problema identificado foi a ausência de padronização dos dados das secretarias do município, processo ainda realizado manualmente, gerando desorganização e atrasos no compartilhamento desses dados com a população.

O escopo da ideia, denominado como “Marília Datahub”, propõe uma plataforma de integração e padronização dos dados provenientes das diferentes secretarias municipais. A solução utiliza inteligência artificial para fiscalizar a qualidade e consistência dos dados, atribuindo um índice de qualidade (Data Quality Score) e sinalizando inconsistências automaticamente a partir de métricas como: completude, consistência, duplicidade e valores ausentes . Após o tratamento e padronização, os dados são organizados e disponibilizados por meio de um dashboard com indicadores, gráficos e mapeamento administrativo das ocorrências/serviços por secretaria, consolidando relatórios que fortalecem a tomada de decisão orientada por dados dentro da administração municipal, com maior transparência, previsibilidade e agilidade no compartilhamento de informações com a população.

2. JUSTIFICATIVA

Justifica-se este projeto pela necessidade de transformar conceitos teóricos em soluções práticas para a sociedade, aplicando o conhecimento adquirido em sala de aula sobre inteligência artificial e análise de dados para otimizar processos tecnológicos. A proposta busca não apenas a eficiência financeira e operacional, mas também a consolidação das habilidades técnico-científico à partir do desenvolvimento de uma ferramenta real, útil e replicável.

3. OBJETIVOS

3.1 OBJETIVOS GERAIS

Desenvolver uma solução baseada em inteligência artificial para padronizar e automatizar o processo de entrada e análise de dados das secretarias, tornando-o mais rápido, organizado e eficiente. A proposta visa reduzir a necessidade de atividades manuais, diminuir a ocorrência de erros, melhorar o controle das informações administrativas e auxiliar futuras decisões da prefeitura municipal.

3.2 OBJETIVOS ESPECÍFICOS

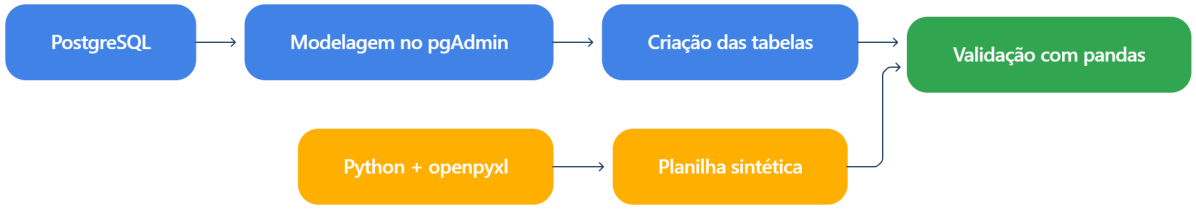
- Desenvolver um sistema automatizado com inteligência artificial para a ingestão, padronização e verificação de qualidade dos dados das secretarias, atribuindo um Data Quality Score para apoiar a análise e a tomada de decisões;
- Reorganizar os dados atualmente dispersos entre as secretarias e consolidar o histórico de registros já existentes;
- Migrar e integrar novos fluxos de dados ao sistema implementado por meio de um processo de mineração estruturado;
- Reduzir o tempo gasto em tarefas operacionais e manuais de tratamento e padronização de dados;
- Aumentar a eficiência e a confiabilidade das informações disponibilizadas à população, por meio de um dashboard com indicadores e mapeamento administrativo.

4. METODOLOGIA

Visando a aplicação de conhecimentos aprendidos no segundo semestre, a metodologia adotada para o desenvolvimento do protótipo da solução *"*Marília DataHub*"* consistiu na idealização de uma arquitetura full-stack que padroniza e automatiza a gestão de dados das secretarias do município, operando da seguinte forma:

4.1 ARQUITETURA DO BANCO DE DADOS

Para a estruturação do banco, será utilizado o PostgreSQL como sistema de gerenciamento de banco de dados, por sua facilidade de utilização e disponibilidade como open-source. As tabelas serão modeladas no pgAdmin, ferramenta que permite desenhar o diagrama entidade-relacionamento e gerar o script SQL de criação automaticamente. Os dados de teste serão gerados em Python, utilizando a biblioteca openpyxl para a criação de uma planilha sintética com formatação e fórmulas. Posteriormente, a biblioteca pandas será utilizada para validar a correspondência entre as informações presentes na planilha e as tabelas do banco de dados.



Fluxograma da Arquitetura do Banco de Dados

4.2 MINERAÇÃO DE DADOS

A mineração de dados será realizada à partir da linguagem Python, utilizando, principalmente, as bibliotecas Pandas e NumPy para análise e tratamento dos datasets disponibilizados como planilha Excel. Serão identificadas e corrigidas inconsistências como diferenças na escrita de secretarias, unidades e bairros, formatos de datas e registros duplicados. Também será realizada a padronização dos dados conforme as regras definidas dentro do escopo, mantendo um registro das alterações realizadas (Data Passport). Na sequência, os datasets tratados serão organizados para serem utilizados nas etapas seguintes de controle de qualidade e disponibilização dos dados.

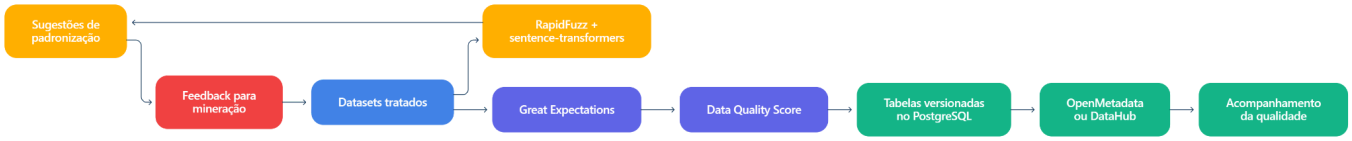


Fluxograma da Mineração de Dados

4.3 CONTROLE DE QUALIDADE POR IA

Para a criação das métricas do Data Quality Score, será utilizado o Great Expectations, priorizando inicialmente regras simples e explicáveis, como o percentual de campos vazios. Para detectar inconsistências e identificar campos ou categorias equivalentes escritos de formas diferentes entre as secretarias, serão utilizadas as bibliotecas RapidFuzz (fuzzy matching) e sentence-transformers (embeddings semânticos), que também geram sugestões de padronização acompanhadas do motivo, como o grau de similaridade entre os termos.

As sugestões retornam ao fluxo de mineração como feedback, e o score é registrado por versão do dataset em tabelas versionadas no PostgreSQL, expostas no catálogo de metadados (OpenMetadata ou DataHub), permitindo acompanhar a evolução da qualidade ao longo do tempo e apoiar os responsáveis na correção de suas bases.



Fluxograma do Controle de Qualidade por IA

4.4 BACKEND

O backend será desenvolvido utilizando Python com FastAPI, dupla escolhida pela sua eficiência, leveza e fácil integração com o ecossistema de dados adotado no projeto. A arquitetura do backend será responsável por disponibilizar os dados padronizados por meio de APIs, com autenticação e autorização utilizando Keycloak, OAuth2 e tokens JWT, além do controle de acesso conforme usuários, secretarias e classificação dos dados, complementado pelo Row-Level Security (RLS) do PostgreSQL.



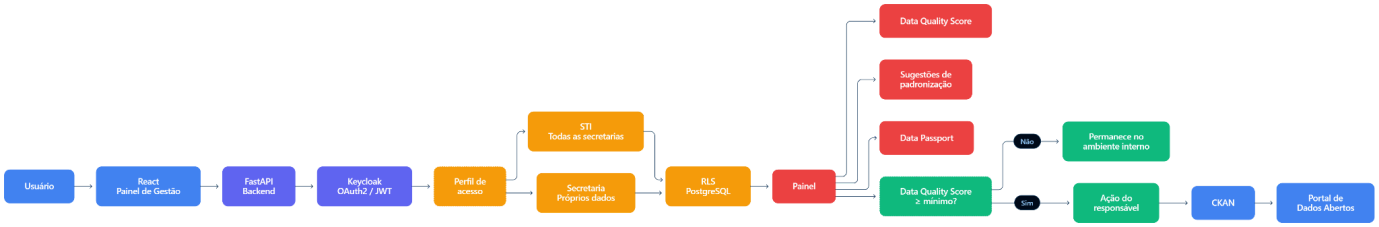
Fluxograma do Backend

4.5 FRONTEND

O frontend da gestão pública será desenvolvido em React, consumindo a API do backend em FastAPI e reutilizando a autenticação via Keycloak/OAuth2/JWT, com as telas adaptadas ao papel do usuário: administradores da STI visualizam todas as secretarias, enquanto cada secretaria acessa apenas seus próprios dados, reforçado pelo RLS do PostgreSQL. O painel exibe o Data Quality Score, as sugestões de padronização e o Data Passport de cada secretaria. A disponibilização dos dados abertos será feita via CKAN, para onde são enviados, mediante ação do responsável no painel interno, apenas os

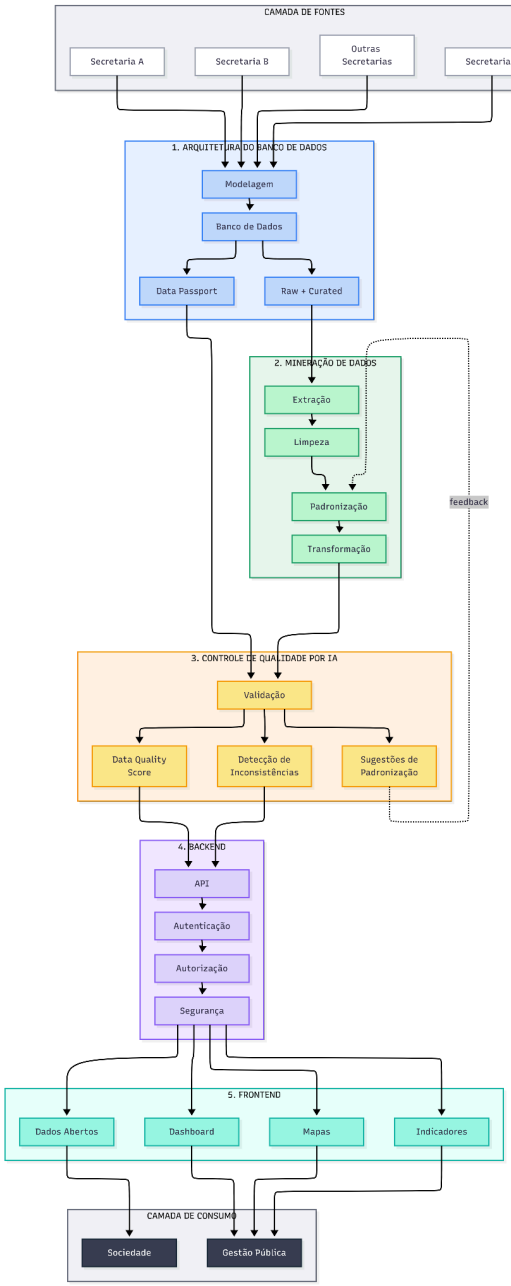
datasets que atingirem o Data Quality Score mínimo definido, garantindo que o portal público exiba somente dados já tratados e validados.

O protótipo interativo do painel de gestão pública, contemplando as telas descritas, pode ser acessado no link a seguir: Frontend (Clicar em *Pré-Visualização* para navegar)



Fluxograma do Frontend

4.6 FLUXOGRAMA GERAL



Fluxograma Geral

5. DESENVOLVIMENTO

A primeira etapa da solução consistiu no estabelecimento das cinco frentes que se complementam: a estrutura de armazenamento dos dados, o tratamento e a padronização, a avaliação da qualidade com apoio de inteligência artificial, a disponibilização segura dos dados e, por fim, a apresentação em um painel de visualização. Ao longo dessa etapa, também foram definidas as ferramentas e bibliotecas de cada frente, a divisão das responsabilidades entre os integrantes do grupo de acordo com cada área de desenvolvimento e elaboradas a documentação do projeto e a apresentação da prototipação.

As próximas etapas envolvem a estruturação do banco de dados, a separação entre dados originais e tratados, a implementação dos processos automatizados de limpeza e padronização, a aplicação do mecanismo de avaliação da qualidade das bases, com geração de notas e sugestões de correção, a implementação do controle de acesso e das regras de proteção de dados e, por fim, o desenvolvimento do painel de visualização e do portal de dados abertos.

6. RESULTADOS PRELIMINARES

Como resultados preliminares, foram definidas as cinco frentes que compõem a solução: armazenamento dos dados, tratamento e padronização, avaliação da qualidade com apoio de IA, disponibilização segura dos dados e painel de visualização. Na sequência, foram escolhidas as ferramentas de cada frente, divididas as responsabilidades entre os integrantes e elaboradas a documentação e a apresentação do escopo.

Na arquitetura de dados, foi construído um modelo relacional de 7 tabelas organizados em estrutura organizacional (secretarias, unidades e bairros), com catálogo de datasets, dicionário de dados e Data Passport, que registra o histórico de versões de cada conjunto de dados. O modelo foi implementado em PostgreSQL, com script de criação testado e validado com uma planilha de 5 datasets sintéticos, permitindo verificar se o catálogo e o dicionário representam corretamente diferentes conjuntos de informações e seus relacionamentos.

Os próximos passos são alinhar a arquitetura de dados aos requisitos das demais etapas, integrando usuários, secretarias, versões e classificações de dados, dando sequência à implementação da limpeza e padronização automatizadas, do Data Quality Score, do controle de acesso e do painel de visualização com o portal de dados abertos.

7. REFERÊNCIAS BIBLIOGRÁFICAS

ALMEIDA, A. T. S. B. de; LOPES, G. S.; NASCIMENTO, J. D. M.; IBUSUKI, U. **O impacto da Indústria 4.0 na qualidade e como as tecnologias habilitadoras beneficiam a operação.** AEA – Simpósio Internacional de Engenharia Automotiva – SIMEA 2024, São Paulo, Brasil, 2024. Disponível em: O impacto da Indústria 4.0 na qualidade e como as tecnologias habilitadoras beneficiam a operação

MARÍLIA (Município). Secretaria Municipal de Tecnologia da Informação. **Política de backup**. Marília, SP: Secretaria Municipal de Tecnologia da Informação. Disponível em: https://www.marilia.sp.gov.br/arquivos/politica_de_backup_22030659.pdf

SCIPOPULIS. **Plancity: tire seu Plano de Metas do papel!** [S. l.]: Scipopulis. Disponível em: https://scipopulis.com/plancity